

强化学习原理：基于策略梯度的方法

郭宪

人工智能学院

College of Artificial Intelligence



南開大學
Nankai University



强化学习的问题形式化

序贯决策问题可以形式化为：

$$\max_{\pi} J(\pi) = \sum_{s,a} \mu^{\pi}(s) \pi(s,a) R(s,a)$$

$$s.t. \mu^{\pi}(s') = \sum_{s,a} \mu^{\pi}(s) \pi(s,a) T(s,a,s')$$

$$1 = \sum_{s,a} \mu^{\pi}(s) \pi(s,a)$$

$$\pi(s,a) \geq 0, \forall s \in S, a \in A$$

1. 该问题的原问题是直接得到最优策略。基于直接策略搜索的强化学习。
2. 该问题的对偶问题是得到最优的值函数，然后由值函数构建最优策略。基于值函数的强化学习。



动态规划的本质

动态规划的本质是：将多阶段决策问题通过贝尔曼方程转化为多个单阶段的决策问题

离散贝尔曼方程：

$$\begin{aligned} J^*[x(j), j] &= \min_{u(j) \in U} \min_{\{u(j+1), \dots, u(N-1)\} \in U} \{L[x(j), u(j), j] + \sum_{k=j+1}^{N-1} L[x[k], u[k], k]\} \\ &= \min_{\substack{u(j) \in U \\ x(j+1) \in X}} \{L(x(j), u(j), j) + J^*[x(j+1), j+1]\} \\ &= \min_{\substack{u(j) \in U \\ x(j+1) \in X}} \{L(x(j), u(j), j) + J^*[f[x(j), u(j), j], j+1]\} \end{aligned}$$

求出值函数后，通过贪婪策略重构出最优策略



最优控制中的动态规划

动态规划的本质是：将多阶段决策问题通过贝尔曼方程转化为多个单阶段的决策问题

连续贝尔曼方程：

$$J^*[x(t), t] = \min_{u[t, t+\Delta t]} \left\{ \min_{u[t+\Delta t, t_f]} \left[\int_t^{t+\Delta t} L(x(\tau), u(\tau), \tau) d\tau + \int_{t+\Delta t}^{t_f} L(x(\tau), u(\tau), \tau) d\tau + \varphi[x(t_f), t_f] \right] \right\}$$
$$= \min_{\substack{u(\tau) \in U \\ t \leq \tau \leq t+dt}} \left\{ \int_t^{t+dt} L[x(\tau), u(\tau), \tau] d\tau + J^*[x(t) + dx(t), t + dt] \right\} \quad (1)$$

将 $J^*[x(t) + dx(t), t + dt]$ 进行泰勒展开有：

$$J^*[x(t) + dx(t), t + dt] = J^*[x(t), t] + \frac{\partial J^*[x(t), t]}{\partial x^T(t)} dx(t) + \frac{\partial J^*[x(t), t]}{\partial t} dt + \varepsilon[dx(t), dt] \quad (2)$$

将 (2) 带入 (1)，并令 $dt \rightarrow 0$ **Hamilton-Jacobi-Bellman方程**

胡寿松等，最优控制理论与系统，科学出版社，2005

$$-\frac{\partial J^*[x(t), t]}{\partial t} = \min_{u(t) \in U} \{ L[x(t), u(t), t] + \frac{\partial J^*[x(t), t]}{\partial x^T(t)} f[x(t), u(t), t] \} \xRightarrow{\text{重构}} \min_{u(t) \in U} \{ L[x(t), u(t), t] + \frac{\partial J^*[x(t), t]}{\partial x^T(t)} f[x(t), u(t), t] \}$$


为什么要策略搜索？

表格型强化学习：

	a_1	a_2	a_3	a_4	a_5
s_1	$Q(s_1, a_1)$	$Q(s_1, a_2)$	$Q(s_1, a_3)$	$Q(s_1, a_4)$	$Q(s_1, a_5)$
s_2	$Q(s_2, a_1)$	...	...	...	...
s_3	...	...	...	...	...
s_4	...	...	...	...	...
s_5	...	...	...	...	...
s_6	...	...	...	...	...
s_7	...	...	...	...	...

$$\pi(s) = \arg \max_a Q(s, a)$$


函数逼近强化学习：



$$\pi(s) = \arg \max_a Q_W(s, a)$$

1. MC方法; 2. TD方法

动作的选择一定要值函数？



利用值函数学习时，策略改进需要求解：

$$\arg \max_a Q_w(s, a)$$

当要解决的问题的动作空间很大或连续时，
该式无法求解。

动作的选择一定要行为值函数吗？

未必！

可以直接得到最优的策略。

策略的定义：

一个策略 π 是给定状态 s 时，动作集上的一个分布：

$$\pi(a|s) = p[A_t = a | S_t = s]$$




常见的直接策略搜索



常用的直接策略搜索的方法：


1. 利用梯度的方法
2. 基于EM的方法
3. 基于路径积分的方法
4. 基于模型的方法
5. 基于粒子滤波的方法

策略搜索方法分类




策略进行参数化

策略的表示:



学习: $\ominus$



如何获得样本点?

标签? 值函数的帮助! 强化学习



策略搜索的好处



(1) 对于离散的动作空间，参数化策略可表示为：

$$\pi(a|s; \theta) = \frac{e^{h(s,a;\theta)}}{\sum_b e^{h(s,b;\theta)}}$$

该策略表示可以逼近一个确定性策略，而 $\varepsilon - greedy$ 不能逼近确定性策略。

与玻尔兹曼策略的区别：

$$\pi(a|s; \theta) = \frac{e^{\frac{Q(s,a)}{\tau}}}{\sum_b e^{\frac{Q(s,b)}{\tau}}}$$

但是玻尔兹曼策略不允许逼近确定性策略。动作值估计将收敛到相应的真实值。收敛到行为值函数对应的概率真实分布。

(2) 参数化的策略可以逼近任意概率分布，不受行为值函数的限制

(3) 策略是更简单的函数逼近，如PID控制

(4) 策略参数化更容易加入先验知识

似然率策略梯度

用 τ 表示一组状态-行为序列 $s_0, u_0, \dots, s_H, u_H$

重载符号: $R(\tau) = \sum_{t=0}^H R(s_t, u_t)$

目标函数为:

$$U(\theta) = E\left(\sum_{t=0}^H R(s_t, u_t); \pi_\theta\right) = \sum_{\tau} P(\tau; \theta) R(\tau)$$

强化学习的目标是找到最优参数 θ 使得:

$$\max_{\theta} U(\theta) = \max_{\theta} \sum_{\tau} P(\tau; \theta) R(\tau)$$

目标函数对参数求导:

$$\begin{aligned} \nabla_{\theta} U(\theta) &= \nabla_{\theta} \sum_{\tau} P(\tau; \theta) R(\tau) \\ &= \sum_{\tau} \nabla_{\theta} P(\tau; \theta) R(\tau) \\ &= \sum_{\tau} \frac{P(\tau; \theta)}{P(\tau; \theta)} \nabla_{\theta} P(\tau; \theta) R(\tau) \\ &= \sum_{\tau} P(\tau; \theta) \frac{\nabla_{\theta} P(\tau; \theta) R(\tau)}{P(\tau; \theta)} \\ &= \sum_{\tau} P(\tau; \theta) \nabla_{\theta} \log P(\tau; \theta) R(\tau) \end{aligned}$$

利用经验平均估计策略的梯度:

$$\nabla_{\theta} U(\theta) \approx \hat{g} = \frac{1}{m} \sum_{i=1}^m \nabla_{\theta} \log P(\tau; \theta) R(\tau)$$



从重要性采样的视角进行推导



目标函数为：

$$U(\theta) = E\left(\sum_{t=0}^H R(s_t, u_t); \pi_{\theta}\right) = \sum_{\tau} P(\tau; \theta) R(\tau)$$

利用重要性采样，可以利用已知参数为 θ_{old} 的策略产生的数据，对任意参数为 θ 的策略进行评估：

$$U(\theta) = E_{\tau \sim \theta_{old}} \left[\frac{P(\tau|\theta)}{P(\tau|\theta_{old})} R(\tau) \right]$$

导数为：

$$\nabla_{\theta} U(\theta) = E_{\tau \sim \theta_{old}} \left[\frac{\nabla_{\theta} P(\tau|\theta)}{P(\tau|\theta_{old})} R(\tau) \right]$$

同分布评价：

$$\nabla_{\theta} U(\theta)|_{\theta=\theta_{old}} = E_{\tau \sim \theta_{old}} \left[\frac{\nabla_{\theta} P(\tau|\theta)|_{\theta_{old}}}{P(\tau|\theta_{old})} R(\tau) \right]$$

$$\nabla_{\theta} U(\theta)|_{\theta=\theta_{old}} = E_{\tau \sim \theta_{old}} [\nabla_{\theta} \log P(\tau|\theta)|_{\theta_{old}} R(\tau)]$$

不仅仅能推导出策略梯度公式，我们还能得到新的**损失函数**：

$$U(\theta) = E_{\tau \sim \theta_{old}} \left[\frac{P(\tau|\theta)}{P(\tau|\theta_{old})} R(\tau) \right]$$

似然率策略梯度的直观理解

利用经验平均估计策略的梯度：


$$\nabla_{\theta} U(\theta) \approx \hat{g} = \frac{1}{m} \sum_{i=1}^m \nabla_{\theta} \log P(\tau; \theta) R(\tau)$$

$\nabla_{\theta} \log P(\tau^{(i)}; \theta) \underbrace{R(\tau^{(i)})}_{\text{增加高回报路径的概率, 减小低回报路径的概率}}$

$$\nabla_{\theta} \log P(\tau^{(j)}; \theta) R(\tau^{(j)})$$

$$\underbrace{\nabla_{\theta} \log P(\tau^{(i)}; \theta)}_{\text{只改变经验路径的概率, 并不改变路径。}} R(\tau^{(i)})$$

只改变经验路径的概率，并不改变路径。



策略梯度的直观理解图

路径似然率推导

利用经验平均估计策略的梯度：

$$\nabla_{\theta} U(\theta) \approx \hat{g} = \frac{1}{m} \sum_{i=1}^m \nabla_{\theta} \log P(\tau^{(i)}; \theta) R(\tau^{(i)})$$

$$R(\tau) = \sum_{t=0}^H R(s_t, u_t)$$

$$\nabla_{\theta} \log P(\tau; \theta) ?$$

$$\tau = s_0, u_0, \dots, s_H, u_H$$

$$P(\tau^{(i)}; \theta) = \prod_{t=0}^H \underbrace{P(s_{t+1}^{(i)} | s_t^{(i)}, u_t^{(i)})}_{\text{动力学}} \cdot \underbrace{\pi_{\theta}(u_t^{(i)} | s_t^{(i)})}_{\text{策略}}$$

路径似然率：

$$\nabla_{\theta} \log P(\tau^{(i)}; \theta) = \nabla_{\theta} \log \left[\prod_{t=0}^H P(s_{t+1}^{(i)} | s_t^{(i)}, u_t^{(i)}) \cdot \pi_{\theta}(u_t^{(i)} | s_t^{(i)}) \right]$$

$$= \nabla_{\theta} \left[\sum_{t=0}^H \log P(s_{t+1}^{(i)} | s_t^{(i)}, u_t^{(i)}) + \sum_{t=0}^H \log \pi_{\theta}(u_t^{(i)} | s_t^{(i)}) \right]$$

$$= \nabla_{\theta} \left[\sum_{t=0}^H \log \pi_{\theta}(u_t^{(i)} | s_t^{(i)}) \right]$$


$$= \sum_{t=0}^H \nabla_{\theta} \log \pi_{\theta}(u_t^{(i)} | s_t^{(i)})$$

只与策略有关，不要求动力学已知

$$\log \pi_{\theta}(u_t^{(i)} | s_t^{(i)}) ?$$

常见的策略表示：离散动作空间

求解： $\nabla_{\theta} \log \pi_{\theta}(u_t^{(i)} | s_t^{(i)})$



常见的策略表示：连续动作空间

求解： $\nabla_{\theta} \log \pi_{\theta}(u_t^{(i)} | s_t^{(i)})$

随机策略可以写为确定性策略加随机部分，即：

$$\pi_{\theta} = \mu_{\theta} + \varepsilon$$

其中 $\varepsilon \sim N(0, \sigma^2)$ 是均值为零，标准差为 σ 的正态分布

其中确定性部分常见的表示为：

线性策略： $\mu(s) = \phi(s)^T \theta$

径向基策略： $\pi_{\theta}(s) = \omega^T \phi(s)$,

其中： $\phi_i(s) = \exp\left(-\frac{1}{2}(s - \mu_i)^T D_i(s - \mu_i)\right)$

参数为： $\theta = \{\omega, \mu_i, d_i\}$

以线性策略为例：

$$\pi(u|s) \sim \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(u - \phi(s)^T \theta)^2}{2\sigma^2}\right)$$


$$\nabla_{\theta} \log \pi_{\theta}(u_t^{(i)} | s_t^{(i)}) = \frac{(u_t^{(i)} - \phi(s_t^{(i)})^T \theta) \phi(s_t^{(i)})}{\sigma^2}$$

方差参数用来控制策略的探索性

随机策略梯度的推导及解释

$$\nabla_{\theta} U(\theta) \approx \frac{1}{m} \sum_{i=1}^m \sum_{t=0}^{H-1} \nabla_{\theta} \log \pi_{\theta}(u_t^{(i)} | s_t^{(i)}) \left(\sum_{k=t}^{H-1} (R(s_k^{(i)}) - b) \right)$$

状态层面解释策略梯度：





REINFORCE: Monte Carlo Policy Gradient

REINFORCE 更新

$$\theta_{t+1} \doteq \theta_t + \alpha G_t \nabla \log \pi(a_t | s_t; \theta_t)$$

REINFORCE: Monte-Carlo Policy-Gradient Control (episodic) for π_*

Input: a differentiable policy parameterization $\pi(a|s, \theta)$

Algorithm parameter: step size $\alpha > 0$

Initialize policy parameter $\theta \in \mathbb{R}^{d'}$ (e.g., to $\mathbf{0}$)

Loop forever (for each episode):

Generate an episode $S_0, A_0, R_1, \dots, S_{T-1}, A_{T-1}, R_T$, following $\pi(\cdot|\cdot, \theta)$

Loop for each step of the episode $t = 0, 1, \dots, T - 1$:


$$G \leftarrow \sum_{k=t+1}^T \gamma^{k-t-1} R_k \quad (G_t)$$

$$\theta \leftarrow \theta + \alpha \gamma^t G \nabla \ln \pi(A_t | S_t, \theta)$$

减小方差方法：基线

利用经验平均估计策略的梯度：

$$\nabla_{\theta} U(\theta) \approx \hat{g} = \frac{1}{m} \sum_{i=1}^m \nabla_{\theta} \log P(\tau^{(i)}; \theta) R(\tau^{(i)})$$



$$\nabla_{\theta} U(\theta) \approx \hat{g} = \frac{1}{m} \sum_{i=1}^m \left(\sum_{t=0}^H \nabla_{\theta} \log \pi_{\theta}(u_t^{(i)} | s_t^{(i)}) R(\tau^{(i)}) \right)$$

该式给出的策略梯度是无偏的，但是方差很大。

$$\nabla_{\theta} U(\theta) \approx \hat{g} = \frac{1}{m} \sum_{i=1}^m \nabla_{\theta} \log P(\tau^{(i)}; \theta) R(\tau^{(i)})$$

$$= \frac{1}{m} \sum_{i=1}^m \nabla_{\theta} \log P(\tau^{(i)}; \theta) (R(\tau^{(i)}) - b)$$

$$E[\nabla_{\theta} \log P(\tau; \theta) b]$$

$$= \sum_{\tau} P(\tau; \theta) \nabla_{\theta} \log P(\tau; \theta) b$$

$$= \sum_{\tau} P(\tau; \theta) \frac{\nabla_{\theta} P(\tau; \theta) b}{P(\tau; \theta)}$$

$$= \sum_{\tau} \nabla_{\theta} P(\tau; \theta) b$$

$$= \nabla_{\theta} \left(\sum_{\tau} P(\tau; \theta) b \right)$$


$$= \nabla_{\theta} b$$

$$= 0$$

减小方差方法：基线

利用经验平均估计策略的梯度：

$$\nabla_{\theta} U(\theta) \approx \hat{g} = \frac{1}{m} \sum_{i=1}^m \nabla_{\theta} \log P(\tau^{(i)}; \theta) R(\tau^{(i)})$$



$$\nabla_{\theta} U(\theta) \approx \hat{g} = \frac{1}{m} \sum_{i=1}^m \left(\sum_{t=0}^H \nabla_{\theta} \log \pi_{\theta}(u_t^{(i)} | s_t^{(i)}) R(\tau^{(i)}) \right)$$

该式给出的策略梯度是无偏的，但是方差很大。

$$\begin{aligned} \nabla_{\theta} U(\theta) \approx \hat{g} &= \frac{1}{m} \sum_{i=1}^m \nabla_{\theta} \log P(\tau^{(i)}; \theta) R(\tau^{(i)}) \\ &= \frac{1}{m} \sum_{i=1}^m \nabla_{\theta} \log P(\tau^{(i)}; \theta) (R(\tau^{(i)}) - b) \end{aligned}$$

如何取b使得方差最小？

$$\text{令 } X = \nabla_{\theta} \log P(\tau^{(i)}; \theta) (R(\tau^{(i)}) - b)$$

则X的方差为：

与b无关

$$\text{Var}(X) = E(X - \bar{X})^2 = EX^2 - \underbrace{(E\bar{X})^2}_{\text{与b无关}}$$

$$\frac{\partial \text{Var}(X)}{\partial b} = E\left(X \frac{\partial X}{\partial b}\right) = 0$$

$$b = \frac{E_p \left[\left(\sum_{t=0}^H \nabla_{\theta} \log \pi_{\theta}(u_t^{(i)} | s_t^{(i)}) \right)^2 R(\tau) \right]}{E_p \left[\left(\sum_{t=0}^H \nabla_{\theta} \log \pi_{\theta}(u_t^{(i)} | s_t^{(i)}) \right)^2 \right]}$$

减小方差方法：修改值函数

REINFORCE方法, 1992, R.J.Williams


$$\nabla_{\theta} U(\theta) \approx \frac{1}{m} \sum_{i=1}^m \left(\sum_{t=0}^H \nabla_{\theta} \log \pi_{\theta}(u_t^{(i)} | s_t^{(i)}) (R(\tau^{(i)}) - b) \right)$$

Policy Gradient Theorem: 1999, R. Sutton


当前的动作与过去的回报无关:

$$E_p[\partial_{\theta} \log \pi_{\theta}(u_t | x_t, t) r_j] = 0 \quad \text{for } j < t$$

$$\nabla_{\theta} U(\theta) \approx \frac{1}{m} \sum_{i=1}^m \sum_{t=0}^{H-1} \nabla_{\theta} \log \pi_{\theta}(u_t^{(i)} | s_t^{(i)}) \left(\sum_{k=t}^{H-1} (R(s_k^{(i)}) - b) \right)$$



$$R(\tau) = \sum_{t=0}^H R(s_t, u_t)$$



减小方差方法：修改值函数



当前的动作与过去的回报无关：

$$E_p[\partial_\theta \log \pi_\theta(u_t | x_t, t) r_j] = 0 \quad \text{for } j < t$$

$$\nabla_\theta U(\theta) \approx \frac{1}{m} \sum_{i=1}^m \sum_{t=0}^{H-1} \nabla_\theta \log \pi_\theta(u_t^{(i)} | s_t^{(i)}) \left(\sum_{k=t}^{H-1} (R(s_k^{(i)}) - b) \right)$$

当前的回报只与过去的动作有关 (G(PO)MDP) :

$$\nabla_\theta U(\theta) \approx \frac{1}{m} \sum_{i=1}^m \sum_{j=0}^{H-1} \left(\sum_{t=0}^j \nabla_\theta \log \pi_\theta(u_t^{(i)} | s_t^{(i)}) (r_j - b_j) \right)$$





第六次作业



1. 阅读《Reinforcement Learning: An Introduction》第13章

