

得分

26

一、单项选择题 (本题共 30 分, 每小题 2 分)

1.1 下列关于强化学习的说法, 不正确的是 (A)

A. 到 1998 年, 已经出现了各种直接策略搜索算法

B. 试错探索和延迟回报是强化学习的两个重要特征

C. 强化学习是基于采样 (与环境交互) 的方法, 学习最优策略

D. 强化学习和监督学习都是从数据中学习, 逐步改善性能

1.2 下列关于马尔科夫决策过程的说法, 不正确的是 (B)

A. 马尔科夫性: 系统的下一个状态只与当前状态有关, 与以前状态无关

B. 马尔科夫决策过程由五元组 (S, A, P, R, γ) 描述

C. 马尔科夫决策过程的当前状态蕴含了所有相关的历史信息

D. 马尔科夫决策过程中, 智能体的目标总是最大化立即回报

1.3 下列关于策略的下面论述, 不正确的是 (B)

A. 一个策略 π 是给定状态 s 时, 动作集上的一个分布: $\pi(a|s) = P(A=a|S=s)$

B. ϵ -贪心策略:

$$\pi(a|s) = \begin{cases} 1-\epsilon, & a = \arg \max_a Q(s, a), \\ \frac{\epsilon}{|A(s)|}, & a \neq \arg \max_a Q(s, a), \end{cases} \text{ 这里, } |A(s)| \text{ 为状态 } s \text{ 对应的动作的个数}$$

C. 高斯策略: $\pi_\theta = \mu_\theta + \epsilon$, 这里, ϵ 服从正态分布 $N(0, \sigma^2)$

D. 玻尔兹曼分布: $\pi_\theta(a|s) = \frac{\exp(q(s, a; \theta))}{\sum_b \exp(q(s, b; \theta))}$

1.4 下列关于贝尔曼方程的计算公式, 不正确的是 (B)

A. $v_\pi(s) = \sum_{a \in A} \pi(a|s) q_\pi(s, a)$

B. $q_\pi(s, a) = R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_\pi(s')$

C. $v_\pi(s) = \sum_{a \in A} \pi(a|s) \left(R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a v_\pi(s') \right)$

D. $q_\pi(s, a) = R_s^a + \gamma \sum_{s' \in S} P_{ss'}^a \left(R_{s'}^a + \gamma \sum_{s'' \in S} P_{s's''}^a q_\pi(s'', a) \right)$

1.5 下列关于动态规划的论述, 不正确的是 (C)

A. 动态规划本质上将多阶段决策问题通过贝尔曼方程转化为多个单阶段的决策问题

B. 强化学习算法可以看成是动态规划算法, 只是用更少的计算且没有假设完美模型

C. 强化学习中针对马尔可夫决策过程的动态规划, 与控制论中针对最优控制的动态规划, 其思想截然不同, 且没有任何关系

D. 动态规划的核心思想是使用价值函数来结构化的组织对最优策略的搜索

1.6 下列关于蒙特卡洛策略评估的论述, 不正确的是 (C)

A. 蒙特卡洛策略评估可分为首次访问型和每次访问型

B. 蒙特卡洛评估不需要用到 bootstrap

C. 蒙特卡洛评估对单个状态的评估准确性, 依赖其他状态评估是否准确

D. 蒙特卡洛算法仅仅需要经验, 即从真实或者模拟的环境交互中采样得到的状态、动作、受益的序列

1.7 下列说法不正确的是 (A)

A. 在 on-policy 的蒙特卡洛算法中, 用于评估或改进的策略与生成采样数据的策略是不同的

B. 在 off-policy 的蒙特卡洛算法中, 用于评估或改进的策略与生成采样数据的策略是不同的

C. 在蒙特卡洛算法中, 估计值为无偏估计

D. TD(0) 对值函数的估计值的方差比蒙特卡洛方法要小很多

1.8 下列说法错误的是 (C)

A. 策略迭代算法包括策略评估和策略改进两个步骤

B. 策略评估可以使用迭代算法实现

C. 值迭代不包括策略评估

D. 蒙特卡洛强化学习算法是无模型强化学习算法

1.9 以下关于时间差分强化学习算法说法错误的是 (C)

A. SARSA 算法是 on-policy 强化学习算法 B. Q learning 是 off-policy 强化学习算法

C. Double Qlearning 解决的是步长问题 D. 时间差分强化学习需要用到自举值

1.10 以下关于 DQN 算法表述错误的是 (B)

A. DQN 使用深度神经网络表示行为值函数 B. DQN 的训练框架是 SARSA 算法

C. DQN 使用了独立的目标网络 D. DQN 使用随机经验回放技术

1.11 在策略梯度公式中, 将常数项加入到回报中, 不改变策略梯度的 (C) -2

A. 方差 B. 偏差 C. 误差 D. 协方差

1.12 与策略梯度算法相比, TRPO 解决的是什么问题 (C)

A. 梯度计算问题 B. 值函数评估问题 C. 更新步长问题 D. 策略网络表示问题

1.13 关于 DDPG 算法表述错误的是 (A) X -2

A. DDPG 算法中的行为值函数训练借鉴了 DQN 算法中训练技巧

B. 确定性策略梯度通过链式法则即可求解

C. DDPG 是 On-policy 强化学习算法

D. DDPG 中有四套不同的网络参数

1.14 下列不属于多智能体强化学习算法的是 (C)

A. Minimax-Q B. Nash Q-learning C. Actor-Critic D. WoLF

1.15 关于 MADDPG 算法表述错误的是 (D)

A. 该算法是集中式训练分布式执行框架

B. 在协同、竞争和混合任务中都可以使用

C. 该算法是多智能体强化学习算法

D. 该算法使用随机策略梯度更新每个智能体的策略