

第五章 移动机器人感知技术

SVD 算法与 ICP 算法

孙 雷 教授

sunl@nankai.edu.cn

Tel: 13512967601

机器人与信息自动化研究所 (IRAIS)
天津市智能机器人技术重点实验室 (tjKLIR)
南开大学

2026 年 4 月 20 日

主要内容

基于 SVD 的机器人定位算法

问题描述

利用最小二乘法计算转移矩阵 t

计算旋转矩阵 R

算法流程

基于 ICP 的点云匹配算法


问题描述

计算最近点集

优化算法

总结

激光定位原理图示



问题描述

Given:

Two **corresponding point sets** $P \in R^{2 \times n}$ based on the world coordinate system, and $Q \in R^{2 \times n}$ based on the laser coordinate system:

$$P = \{p_1, p_2, \dots, p_n\}$$

$$Q = \{q_1, q_2, \dots, q_n\}$$

Goal:

为了计算出它们之间的刚体变换，即 R 和 t ，可以将其建模为如下的数学形式：

$$(R, t) = \arg \min \sum_{i=1}^n w_i \| (Rp_i + t) - q_i \|^2 \quad (1)$$

w_i 表示每个点对之间的权重。



利用最小二乘法计算转移矩阵 t

- 首先，对公式 (1) 求导，可以得到：

$$\frac{\partial F}{\partial t} = 2t \left(\sum_{i=1}^n w_i \right) + 2R \left(\sum_{i=1}^n w_i p_i \right) - 2 \sum_{i=1}^n w_i q_i = 0 \quad (2)$$



利用最小二乘法计算转移矩阵 t

- 首先，对公式 (1) 求导，可以得到：

$$\frac{\partial F}{\partial t} = 2t \left(\sum_{i=1}^n w_i \right) + 2R \left(\sum_{i=1}^n w_i p_i \right) - 2 \sum_{i=1}^n w_i q_i = 0 \quad (2)$$

- 引入点集合 P 的加权中心点 $\hat{p}$ 和点集合 Q 的加权中心点 $\hat{q}$ ，它们分别为：

$$\hat{p} = \frac{\sum_{i=1}^n w_i p_i}{\sum_{i=1}^n w_i} \quad \hat{q} = \frac{\sum_{i=1}^n w_i q_i}{\sum_{i=1}^n w_i} \quad (3)$$



利用最小二乘法计算转移矩阵 t

- 首先，对公式 (1) 求导，可以得到：

$$\frac{\partial F}{\partial t} = 2t \left(\sum_{i=1}^n w_i \right) + 2R \left(\sum_{i=1}^n w_i p_i \right) - 2 \sum_{i=1}^n w_i q_i = 0 \quad (2)$$

- 引入点集合 P 的加权中心点 $\hat{p}$ 和点集合 Q 的加权中心点 $\hat{q}$ ，它们分别为：

$$\hat{p} = \frac{\sum_{i=1}^n w_i p_i}{\sum_{i=1}^n w_i} \quad \hat{q} = \frac{\sum_{i=1}^n w_i q_i}{\sum_{i=1}^n w_i} \quad (3)$$

- 公式 (2) 两边同时除以 $\sum_{i=1}^n w_i$ ，则得到：

$$t = \hat{q} - R\hat{p} \quad (4)$$



更新优化目标

- 优化目标变换：将公式 (4) 带入到公式 (1) 可以得到：

$$\begin{aligned}\sum_{i=1}^n w_i \| (Rp_i + t) - q_i \|^2 &= \sum_{i=1}^n w_i \| Rp_i + \hat{q} - R\hat{p} - q_i \|^2 \\ &= \sum_{i=1}^n w_i \| R(p_i - \hat{p}) - (q_i - \hat{q}) \|^2\end{aligned}\tag{5}$$

更新优化目标

- **优化目标变换：**将公式 (4) 带入到公式 (1) 可以得到：

$$\begin{aligned}\sum_{i=1}^n w_i \|(Rp_i + t) - q_i\|^2 &= \sum_{i=1}^n w_i \|Rp_i + \hat{q} - R\hat{p} - q_i\|^2 \\ &= \sum_{i=1}^n w_i \|R(p_i - \hat{p}) - (q_i - \hat{q})\|^2\end{aligned}\quad (5)$$

- **去中心化：**引入用集合 X 和集合 Y 表示 $p_i - \hat{p}$ 和 $q_i - \hat{q}$ ，用 x_i 和 y_i 分别表示去中心化后的点。

$$x_i := p_i - \hat{p} \quad y_i := q_i - \hat{q} \quad (6)$$

更新优化目标

- **优化目标变换：**将公式 (4) 带入到公式 (1) 可以得到：

$$\begin{aligned}\sum_{i=1}^n w_i \|(Rp_i + t) - q_i\|^2 &= \sum_{i=1}^n w_i \|Rp_i + \hat{q} - R\hat{p} - q_i\|^2 \\ &= \sum_{i=1}^n w_i \|R(p_i - \hat{p}) - (q_i - \hat{q})\|^2\end{aligned}\quad (5)$$

- **去中心化：**引入用集合 X 和集合 Y 表示 $p_i - \hat{p}$ 和 $q_i - \hat{q}$ ，用 x_i 和 y_i 分别表示去中心化后的点。

$$x_i := p_i - \hat{p} \quad y_i := q_i - \hat{q} \quad (6)$$

- **更新优化目标：**这时所以公式 (1) 可以等价于为：

$$R = \arg \min \sum_{i=1}^n w_i \|Rx_i - y_i\|^2 \quad (7)$$



求取旋转矩阵 R

- 扩展公式 (7):

$$\begin{aligned}\|Rx_i - y_i\|^2 &= (Rx_i - y_i)^T (Rx_i - y_i) \\ &= x_i^T R^T R x_i - y_i^T R x_i - x_i^T R^T y_i + y_i^T y_i\end{aligned}\quad (8)$$

求取旋转矩阵 R

- 扩展公式 (7):

$$\begin{aligned}\|Rx_i - y_i\|^2 &= (Rx_i - y_i)^T (Rx_i - y_i) \\ &= x_i^T \boxed{R^T R} x_i - y_i^T Rx_i - x_i^T R^T y_i + y_i^T y_i\end{aligned}\tag{8}$$

标准正交阵

求取旋转矩阵 R

- 扩展公式 (7):

$$\begin{aligned}\|Rx_i - y_i\|^2 &= (Rx_i - y_i)^T (Rx_i - y_i) \\ &= x_i^T \boxed{R^T R} x_i - y_i^T Rx_i - x_i^T R^T y_i + y_i^T y_i\end{aligned}\tag{8}$$

标准正交阵

- 标准正交阵: $R^T R = I$;

求取旋转矩阵 R

- 扩展公式 (7):

$$\begin{aligned}\|Rx_i - y_i\|^2 &= (Rx_i - y_i)^T (Rx_i - y_i) \\ &= x_i^T \underbrace{R^T R}_{\text{标准正交阵}} x_i - y_i^T R x_i - \underbrace{x_i^T R^T y_i}_{\text{标量 } R^{1 \times 1}} + y_i^T y_i\end{aligned}\quad (8)$$

- 标准正交阵: $R^T R = I$;

求取旋转矩阵 R

- 扩展公式 (7):

$$\begin{aligned}\|Rx_i - y_i\|^2 &= (Rx_i - y_i)^T (Rx_i - y_i) \\ &= x_i^T \underbrace{R^T R}_{\text{标准正交阵}} x_i - y_i^T R x_i - \underbrace{x_i^T R^T y_i}_{\text{标量 } R^{1 \times 1}} + y_i^T y_i\end{aligned}\quad (8)$$

- 标准正交阵: $R^T R = I$;
- 标量: $a^T = a$

求取旋转矩阵 R

- 扩展公式 (7):

$$\begin{aligned}\|Rx_i - y_i\|^2 &= (Rx_i - y_i)^T (Rx_i - y_i) \\ &= x_i^T \underbrace{R^T R}_{\text{标准正交阵}} x_i - y_i^T Rx_i - \underbrace{x_i^T R^T y_i}_{\text{标量 } R^{1 \times 1}} + y_i^T y_i\end{aligned}\quad (8)$$

- 标准正交阵: $R^T R = I$;
- 标量: $a^T = a$
- 公式 (8) 可以变成:

$$\|Rx_i - y_i\|^2 = x_i^T x_i - 2y_i^T Rx_i + y_i^T y_i \quad (9)$$



更新优化目标

- 由式 (9) 代入优化目标函数 (7) 中，可得更新后的优化目标函数为

$$\begin{aligned}\arg \min \sum_{i=1}^n w_i \|R x_i - y_i\|^2 &= \arg \min \sum_{i=1}^n w_i (x_i^T x_i - 2 y_i^T R x_i + y_i^T y_i) \\ &= \arg \min \left(\sum_{i=1}^n w_i x_i^T x_i - 2 \sum_{i=1}^n w_i y_i^T R x_i + \sum_{i=1}^n w_i y_i^T y_i \right)\end{aligned}$$



更新优化目标

- 由式 (9) 代入优化目标函数 (7) 中，可得更新后的优化目标函数为

$$\begin{aligned}\arg \min \sum_{i=1}^n w_i \|Rx_i - y_i\|^2 &= \arg \min \sum_{i=1}^n w_i (x_i^T x_i - 2y_i^T Rx_i + y_i^T y_i) \\ &= \arg \min \left(\sum_{i=1}^n w_i x_i^T x_i - 2 \sum_{i=1}^n w_i y_i^T Rx_i + \sum_{i=1}^n w_i y_i^T y_i \right)\end{aligned}$$



更新优化目标

- 由式 (9) 代入优化目标函数 (7) 中, 可得更新后的优化目标函数为

$$\begin{aligned}\arg \min \sum_{i=1}^n w_i \|R x_i - y_i\|^2 &= \arg \min \sum_{i=1}^n w_i (x_i^T x_i - 2 y_i^T R x_i + y_i^T y_i) \\ &= \arg \min \left(\sum_{i=1}^n w_i x_i^T x_i - 2 \sum_{i=1}^n w_i y_i^T R x_i + \sum_{i=1}^n w_i y_i^T y_i \right)\end{aligned}$$

- 因为 $\sum_{i=1}^n w_i x_i^T x_i$ 和 $\sum_{i=1}^n w_i y_i^T y_i$ 不依赖于旋转矩阵 R , 所以

更新优化目标

- 由式 (9) 代入优化目标函数 (7) 中, 可得更新后的优化目标函数为

$$\begin{aligned} \arg \min \sum_{i=1}^n w_i \|Rx_i - y_i\|^2 &= \arg \min \sum_{i=1}^n w_i (x_i^T x_i - 2y_i^T Rx_i + y_i^T y_i) \\ &= \arg \min \left(\sum_{i=1}^n w_i x_i^T x_i - 2 \sum_{i=1}^n w_i y_i^T Rx_i + \sum_{i=1}^n w_i y_i^T y_i \right) \end{aligned}$$

- 因为 $\sum_{i=1}^n w_i x_i^T x_i$ 和 $\sum_{i=1}^n w_i y_i^T y_i$ 不依赖于旋转矩阵 R , 所以

$$\begin{aligned} \arg \min \sum_{i=1}^n w_i \|Rx_i - y_i\|^2 &= \arg \min \left(-2 \sum_{i=1}^n w_i y_i^T Rx_i \right) \\ &= \arg \max \left(\sum_{i=1}^n w_i y_i^T Rx_i \right) \end{aligned} \quad (10)$$

求取旋转矩阵 R

- 由式 (10) 中, 对 $\sum_{i=1}^n w_i y_i^T R x_i$ 进行如下变换:

$$\begin{aligned}
 \sum_{i=1}^n w_i y_i^T R x_i &= \text{tr} \left(\begin{bmatrix} w_1 y_1^T R x_1 & & & \\ & w_2 y_2^T R x_2 & & \\ & & \ddots & \\ & & & w_n y_n^T R x_n \end{bmatrix} \right) \\
 &= \text{tr} \left(\begin{bmatrix} w_1 y_1^T \\ w_2 y_2^T \\ \vdots \\ w_n y_n^T \end{bmatrix} [R x_1 \quad R x_2 \quad \cdots \quad R x_n] \right) \\
 &= \text{tr} \left(\begin{bmatrix} w_1 & & & \\ & w_2 & & \\ & & \ddots & \\ & & & w_n \end{bmatrix} \begin{bmatrix} y_1^T \\ y_2^T \\ \vdots \\ y_n^T \end{bmatrix} R [x_1 \quad x_2 \quad \cdots \quad x_n] \right)
 \end{aligned} \tag{11}$$



求取旋转矩阵 R

- 由公式 (11), 优化目标可变为:

$$\arg \max \left(\sum_{i=1}^n w_i y_i^T R x_i \right) = \arg \max (\text{tr} (W Y^T R X)) \quad (12)$$

其中, $W = \text{diag}(w_1, \dots, w_n)$, $X = [x_1, x_2, \dots, x_n]$, $Y = [y_1, y_2, \dots, y_n]$ 。



求取旋转矩阵 R

- 由公式 (11), 优化目标可变为:

$$\arg \max \left(\sum_{i=1}^n w_i y_i^T R x_i \right) = \arg \max (\text{tr}(WY^T R X)) \quad (12)$$

其中, $W = \text{diag}(w_1, \dots, w_n)$, $X = [x_1, x_2, \dots, x_n]$, $Y = [y_1, y_2, \dots, y_n]$ 。

- 矩阵的迹满足 $\text{tr}(AB) = \text{tr}(BA)$, 则

$$\sum_{i=1}^n w_i y_i^T R x_i = \text{tr}(WY^T R X) = \text{tr}((RX)(WY^T)) = \text{tr}(RXWY^T) \quad (13)$$



求取旋转矩阵 R

- 由公式 (11), 优化目标可变为:

$$\arg \max \left(\sum_{i=1}^n w_i y_i^T R x_i \right) = \arg \max (\operatorname{tr}(W Y^T R X)) \quad (12)$$

其中, $W = \operatorname{diag}(w_1, \dots, w_n)$, $X = [x_1, x_2, \dots, x_n]$, $Y = [y_1, y_2, \dots, y_n]$ 。

- 矩阵的迹满足 $\operatorname{tr}(AB) = \operatorname{tr}(BA)$, 则

$$\sum_{i=1}^n w_i y_i^T R x_i = \operatorname{tr}(W Y^T R X) = \operatorname{tr}((R X)(W Y^T)) = \operatorname{tr}(R X W Y^T) \quad (13)$$

- 令 $S = X W Y^T$, 由 SVD 原理, 可知:

$$S = U \Sigma V^T \quad (14)$$

其中, U, V 为单位正交阵, Σ 为对角阵 $\operatorname{diag}(\sigma_1, \sigma_2, \dots, \sigma_n)$ 。



求取旋转矩阵 R

- 将式 (14) 带入式 (13) 可得：

$$\sum_{i=1}^n w_i y_i^T R x_i = \text{tr}(R X W Y^T) = \text{tr}(R U \Sigma V^T) \stackrel{\text{tr}(AB)=\text{tr}(BA)}{=} \text{tr}(\Sigma V^T R U) \quad (15)$$

令 $M = V^T R U$ ，由于 U ， V ， R 均为单位正交阵，则 M 同样也是正交矩阵。这也意味在矩阵 M 中，每一列的向量 m_j ， $m_j^T m_j = 1$ ，

求取旋转矩阵 R

- 将式 (14) 带入式 (13) 可得:

$$\sum_{i=1}^n w_i y_i^T R x_i = \text{tr}(R X W Y^T) = \text{tr}(R U \Sigma V^T) \stackrel{\text{tr}(AB)=\text{tr}(BA)}{=} \text{tr}(\Sigma V^T R U) \quad (15)$$

令 $M = V^T R U$, 由于 U, V, R 均为单位正交阵, 则 M 同样也是正交矩阵。这也意味在矩阵 M 中, 每一列的向量 m_j , $m_j^T m_j = 1$,

- 则式 (15) 可转换成:

$$\begin{aligned} \sum_{i=1}^n w_i y_i^T R x_i &= \text{tr}(\Sigma V^T R U) = \text{tr}(\Sigma M) \\ &= \text{tr} \left(\begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_n \end{bmatrix} \begin{bmatrix} m_{11} & m_{12} & \cdots & m_{1n} \\ m_{21} & m_{22} & \cdots & m_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ m_{n1} & m_{n2} & \cdots & m_{nn} \end{bmatrix} \right) \\ &= \sum_{i=1}^n \sigma_i m_{ii} \leq \sum_{i=1}^n \sigma_i \end{aligned} \quad (16)$$

求取旋转矩阵 R

- 将式 (14) 带入式 (13) 可得:

$$\sum_{i=1}^n w_i y_i^T R x_i = \text{tr}(R X W Y^T) = \text{tr}(R U \Sigma V^T) \stackrel{\text{tr}(AB)=\text{tr}(BA)}{=} \text{tr}(\Sigma V^T R U) \quad (15)$$

令 $M = V^T R U$, 由于 U, V, R 均为单位正交阵, 则 M 同样也是正交矩阵。这也意味在矩阵 M 中, 每一列的向量 m_j , $m_j^T m_j = 1$,

- 则式 (15) 可转换成:

$$\begin{aligned} \sum_{i=1}^n w_i y_i^T R x_i &= \text{tr}(\Sigma V^T R U) = \text{tr}(\Sigma M) \\ &= \text{tr} \left(\begin{bmatrix} \sigma_1 & & & \\ & \sigma_2 & & \\ & & \ddots & \\ & & & \sigma_n \end{bmatrix} \begin{bmatrix} m_{11} & m_{12} & \cdots & m_{1n} \\ m_{21} & m_{22} & \cdots & m_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ m_{n1} & m_{n2} & \cdots & m_{nn} \end{bmatrix} \right) \\ &= \sum_{i=1}^n \sigma_i m_{ii} \leq \sum_{i=1}^n \sigma_i \quad \text{当且仅当 } M = I \text{ 时等号成立} \end{aligned} \quad (16)$$



求取旋转矩阵 R

- 当且仅当 $M = I$ ，式 (16) 取最大值，则

$$V^T R U = I \Rightarrow R = V U^T \quad (17)$$



求取旋转矩阵 R

- 当且仅当 $M = I$ ，式 (16) 取最大值，则

$$V^T R U = I \Rightarrow R = V U^T \quad (17)$$

- 将式 (17) 代入式 (4) 可得：

$$t = \hat{q} - R \hat{p} \quad (18)$$

求取旋转矩阵 R

- 当且仅当 $M = I$ ，式 (16) 取最大值，则

$$V^T R U = I \Rightarrow R = V U^T \quad (17)$$

- 将式 (17) 代入式 (4) 可得：

$$t = \hat{q} - R \hat{p} \quad (18)$$

- 最小的匹配误差为：

$$\arg \min \sum_{i=1}^n w_i \| (R p_i + t) - q_i \|^2 = \sum_{i=1}^n w_i x_i^T x_i + \sum_{i=1}^n w_i y_i^T y_i - 2 \sum_{i=1}^n \sigma_i$$

总结

给定两个在 2 维空间中对应的点集合 $P = \{p_1, p_2, \dots, p_n\}$ 和 $Q = \{q_1, q_2, \dots, q_n\}$:

- 加权平均:

$$\hat{p} = \frac{\sum_{i=1}^n w_i p_i}{\sum_{i=1}^n w_i} \quad \hat{q} = \frac{\sum_{i=1}^n w_i q_i}{\sum_{i=1}^n w_i}$$

其中 w_i 为权重参数, 可根据激光测量距离取 $w_i = 1/\sigma_i(\rho_i)$ 。



总结

给定两个在 2 维空间中对应的点集合 $P = \{p_1, p_2, \dots, p_n\}$ 和 $Q = \{q_1, q_2, \dots, q_n\}$:

- 加权平均:

$$\hat{p} = \frac{\sum_{i=1}^n w_i p_i}{\sum_{i=1}^n w_i} \quad \hat{q} = \frac{\sum_{i=1}^n w_i q_i}{\sum_{i=1}^n w_i}$$

其中 w_i 为权重参数, 可根据激光测量距离取 $w_i = 1/\sigma_i(\rho_i)$ 。

- 去中心化, 将点集 P, Q 转化为 $X = [x_1, x_2, \dots, x_n], Y = [y_1, y_2, \dots, y_n] \in R^{2 \times n}$:

$$x_i := p_i - \hat{p} \quad y_i := q_i - \hat{q}$$



总结

给定两个在 2 维空间中对应的点集合 $P = \{p_1, p_2, \dots, p_n\}$ 和 $Q = \{q_1, q_2, \dots, q_n\}$:

- 加权平均:

$$\hat{p} = \frac{\sum_{i=1}^n w_i p_i}{\sum_{i=1}^n w_i} \quad \hat{q} = \frac{\sum_{i=1}^n w_i q_i}{\sum_{i=1}^n w_i}$$

其中 w_i 为权重参数, 可根据激光测量距离取 $w_i = 1/\sigma_i(\rho_i)$ 。

- 去中心化, 将点集 P, Q 转化为 $X = [x_1, x_2, \dots, x_n], Y = [y_1, y_2, \dots, y_n] \in R^{2 \times n}$:

$$x_i := p_i - \hat{p} \quad y_i := q_i - \hat{q}$$

- 构造 SVD 矩阵, 求取 U, V 单位正交阵:

$$S = XWY^T = U\Sigma V^T, \quad W = \text{diag}(w_1, \dots, w_n) \in R^{n \times n}$$

总结

给定两个在 2 维空间中对应的点集合 $P = \{p_1, p_2, \dots, p_n\}$ 和 $Q = \{q_1, q_2, \dots, q_n\}$:

- 加权平均:

$$\hat{p} = \frac{\sum_{i=1}^n w_i p_i}{\sum_{i=1}^n w_i} \quad \hat{q} = \frac{\sum_{i=1}^n w_i q_i}{\sum_{i=1}^n w_i}$$

其中 w_i 为权重参数, 可根据激光测量距离取 $w_i = 1/\sigma_i(\rho_i)$ 。

- 去中心化, 将点集 P, Q 转化为 $X = [x_1, x_2, \dots, x_n], Y = [y_1, y_2, \dots, y_n] \in R^{2 \times n}$:

$$x_i := p_i - \hat{p} \quad y_i := q_i - \hat{q}$$

- 构造 SVD 矩阵, 求取 U, V 单位正交阵:

$$S = XWY^T = U\Sigma V^T, \quad W = \text{diag}(w_1, \dots, w_n) \in R^{n \times n}$$

- 求取旋转矩阵 R : 根据求取的 U 和 V 得:

$$R = VU^T$$

总结

给定两个在 2 维空间中对应的点集合 $P = \{p_1, p_2, \dots, p_n\}$ 和 $Q = \{q_1, q_2, \dots, q_n\}$:

- 加权平均:

$$\hat{p} = \frac{\sum_{i=1}^n w_i p_i}{\sum_{i=1}^n w_i} \quad \hat{q} = \frac{\sum_{i=1}^n w_i q_i}{\sum_{i=1}^n w_i}$$

其中 w_i 为权重参数, 可根据激光测量距离取 $w_i = 1/\sigma_i(\rho_i)$ 。

- 去中心化, 将点集 P, Q 转化为 $X = [x_1, x_2, \dots, x_n], Y = [y_1, y_2, \dots, y_n] \in R^{2 \times n}$:

$$x_i := p_i - \hat{p} \quad y_i := q_i - \hat{q}$$

- 构造 SVD 矩阵, 求取 U, V 单位正交阵:

$$S = XWY^T = U\Sigma V^T, \quad W = \text{diag}(w_1, \dots, w_n) \in R^{n \times n}$$

- 求取旋转矩阵 R : 根据求取的 U 和 V 得:


$$R = VU^T$$

- 求取平移矩阵 t :


$$t = \hat{q} - R\hat{p}$$

ICP (Iterative Closest Point 迭代最近点算法)

- If correct correspondences are not known, it is generally impossible to determine the optimal relative rotation/translation in one step



激光定位原理图示



ICP with Unknown Data Association

Step 1: 计算最近点集

Step 2: 计算变换矩阵

Step 3: 计算变换矩阵

Step 4: 目标函数计算与阈值判断






图 2.1: ICP 算法流程图


ICP 算法示例




(a) Iterative1




(b) Iterative2




(c) Iterative3



(d) Iterative4



(e) Iterative10



(f) Iterative16

计算最近点集

- 点集 P (传感器检测数据点集) 中有 N_p 个数据点:

$$P = \{\vec{p}_i, i = 1, \dots, N_p\}$$

- 点集 X (目标点集) 中有 N_x 个数据点:

$$X = \{\vec{x}_i, i = 1, \dots, N_x\}$$

- d 为某个数据点 $\vec{p}_i \in P$ 和点集 X 的几何距离:

$$d(\vec{p}_i, X) = \min_{\vec{x} \in X} \|\vec{x} - \vec{p}_i\|$$

- 令 $\vec{y}_i \in X$ 为最近点, 满足:

$$d(\vec{p}_i, \vec{y}_i) = d(\vec{p}_i, X)$$

- 求取最近点集 Y

$$Y = C(P, X) = \{(\vec{p}_i, \vec{y}_i) | d(\vec{p}_i, \vec{y}_i) = d(\vec{p}_i, X), \vec{p}_i \in P, \vec{y}_i \in X, i = 1, \dots, N_p\}$$

数据预处理——点云采样

- 减少计算量

原始点云数据量通常极大（如数万甚至数百万个点），处理所有点会导致计算成本过高。

- 降低噪声干扰

样能筛选出更具代表性的点（如关键点或特征点），减少噪声对匹配过程的干扰，提高配准精度。

- 避免冗余与局部过拟合

密集点云中存在大量相似点，直接使用所有点可能导致算法陷入局部最优（例如误将冗余点视为正确对应）。采样可精简数据，保留关键特征，提升算法的鲁棒性。

- 加速迭代收敛




图 2.2: 3D Scan (海量点云数据 200,000 Points, 空间分布不均匀, 噪声大)



数据预处理——点云采样

- 均匀采样 (Uniform Sampling)
- 随机采样 (Random Sampling)
- 法向量空间采样 (Normal-Space Sampling)
- 基于特征的采样 (Feature based Sampling)
- 体素网格采样 (Voxel-Grid Sampling)

数据预处理——点云采样





图 2.3: 均匀采样





图 2.4: 法向量空间采样

数据预处理——点云采样

基于特征的采样:

- try to find important points
- decrease the number of correspondences
- higher efficiency and higher accuracy
- requires preprocessing




图 2.5: 3D Scan (200,000 Points)




图 2.6: Extracted Features (5,000 Points)



数据预处理——点云采样

基于体素网络的采样:

- 占据体素：均匀采样
- 概率体素：体素内点云分布
- 特征体素：体素内特征提取



计算最近点集-点集匹配

- Closest Point Matching
- Normal Shooting Matching
- Point-to-Plane Matching
- Projection Matching
- Using kd-trees or oc-trees Matching

Notice:


Data association method has greatest effect on convergence and speed

CPM: Closest Point Matching

求取最近点集 Y

$$Y = C(P, X) = \{(\vec{p}_i, \vec{y}_i) | d(\vec{p}_i, \vec{y}_i) = d(\vec{p}_i, X), \vec{p}_i \in P, \vec{y}_i \in X, i = 1, \dots, N_p\}$$


- Closest-point matching generally stable, but slow and requires preprocessing



Normal Shooting Matching

基本思路



- Project along normal, intersect other point set
- Slightly better than closest point for smooth structures, worse for noisy or complex structures



Point-to-Plane Matching

基本思路


Point to Plane 法是根据源曲面上的一个点 $\vec{p}$ ，在目标曲面上找出对应于点 $\vec{p}$ 一个最近的点 $\vec{q}$ 。搜索算法是根据源曲面上点 $\vec{p}$ 的切平面的法线，确定发现于目标曲面的交点 $\vec{q}'$ 。根据目标曲面上 $\vec{q}'$ 点求出的过点 $\vec{q}'$ 切平面，然后求源曲面上点 $\vec{p}$ 到过 $\vec{q}'$ 点切平面的垂线的交点 $\vec{q}$ 。



Projection Matching

基本思路

Point to Projection 最近点搜索法是一种快速的配准方法， O_q 是扫描目标曲面的透视点的位置。Point to Projection 法是根据源曲面上的一个点 $\vec{p}$ 和透视点 O_q ，在目标曲面上找出点 $\vec{q}$ 作为对应于 $\vec{p}$ 点的最近点。通过确定点 O_q 向点 $\vec{p}$ 方向的投影线与目标曲面的交点 $\vec{q}$ ，作为搜索的最近点。



- Slightly worse alignments per iteration
- Each iteration is one to two orders of magnitude faster than closest-point

Point-to-Distribution Matching

Point-to-Point 匹配 (欧式距离):

$$\hat{R} = \arg \max_R \sum_{i=1}^n w_i \| (Rp_i + t) - q_i \|^2$$

Point-to-Distribution 匹配 (马氏距离):

$$\hat{b}_i = \mathbf{T}\hat{a}_i \Rightarrow d_i = \hat{b}_i - \mathbf{T}\hat{a}_i$$

$$\Rightarrow d_i \sim \mathcal{N}(\hat{b}_i - \mathbf{T}\hat{a}_i, \Sigma_b + \mathbf{T}\Sigma_a\mathbf{T}^\top)$$

$$= \mathcal{N}(0, \Sigma_b + \mathbf{T}\Sigma_a\mathbf{T}^\top)$$

$$\hat{T} = \arg \max_T \prod_i p(d_i) = \arg \max_T \sum_i \log(p(d_i))$$

$$= \arg \max_T \sum_{i=1}^n d_i^\top (\Sigma_b + \mathbf{T}\Sigma_a\mathbf{T}^\top)^{-1} d_i$$







图 2.7 马氏距离示意图


ICP 算法示例




ICP 算法示例




ICP 算法示例



ICP 算法示例



ICP 算法示例





总结

- ICP is a powerful algorithm for calculating the displacement between scans.
- The major problem is to determine the correct data associations.
- Given the correct data associations, the transformation can be computed efficiently using SVD.



作业

SVD 算法仿真实验

- 推导 SVD 和 ICP 算法，并进行仿真实验，并对仿真实验结果进行分析，测试所构建模型的正确性
- 将算法的推导过程，仿真实验结果和数据分析补充到大报告之后，提交电子版文档，文件名称：学号 + 专业 + 姓名
- 5 月 10 日晚上 23:59 之前发送邮箱：1537664323@qq.com

第五章 移动机器人感知技术

SVD 算法与 ICP 算法

孙 雷 教授

sunl@nankai.edu.cn

Tel: 13512967601

机器人与信息自动化研究所 (IRAIS)
天津市智能机器人技术重点实验室 (tjKLIR)
南开大学

2026 年 4 月 20 日